

UNIVERSIDAD VERACRUZANA

FACULTAD DE ESTADÍSTICA E INFORMÁTICA



Materia: Metodología de la Investigación

Actividad : Metodología SEMMA

Equipo

- Fabiola López Velázquez
- Joshua Iván Olivares Blanco
- Jorge Luis Ortiz Libreros
-
- Profesor: Lorena López Lozada

Fecha: 28 de septiembre de 2026

Introducción

En este proyecto aplicamos la metodología SEMMA, proceso para desarrollar proyectos de minería de datos y modelado predictivo de manera ordenada. Su nombre proviene de las cinco etapas que la componen: Sample, Explore, Modify, Model y ASSESS. Se aplicó a una base de 15,000 registros con el propósito de construir y evaluar un modelo, para clasificar el riesgo de diabetes en tres niveles: Low, Moderate y High.

El proyecto aborda un problema de clasificación supervisada multiclase: a partir de características demográficas, antropométricas, de estilo de vida y mediciones incluidas en la base, se busca asignar cada observación a uno de tres niveles de diabetes_risk.

Metodología SEMMA

Fase	Aplicación en el proyecto
Sample	Caracterización de la base y partición estratificada 70/30.
Explore	Distribuciones, faltantes, duplicados, estadísticos y gráficos por nivel de riesgo.
Modify	Eliminación del identificador, tratamiento de NA y conversión de variables categóricas.
Model	Árbol rpart multiclase, validación cruzada interna y poda por CP.
Assess	Matriz de confusión, accuracy, Kappa, métricas por clase e importancia de variables.

1. SAMPLE (MUESTREO)

La base original contiene 15,000 observaciones. No se detectaron registros duplicados. La variable objetivo presenta una distribución no uniforme.

Clase	Frecuencia	Porcentaje
Low	9,000	60.00%
Moderate	3,750	25.00%
High	2,250	15.00%
Total	15,000	100.00%

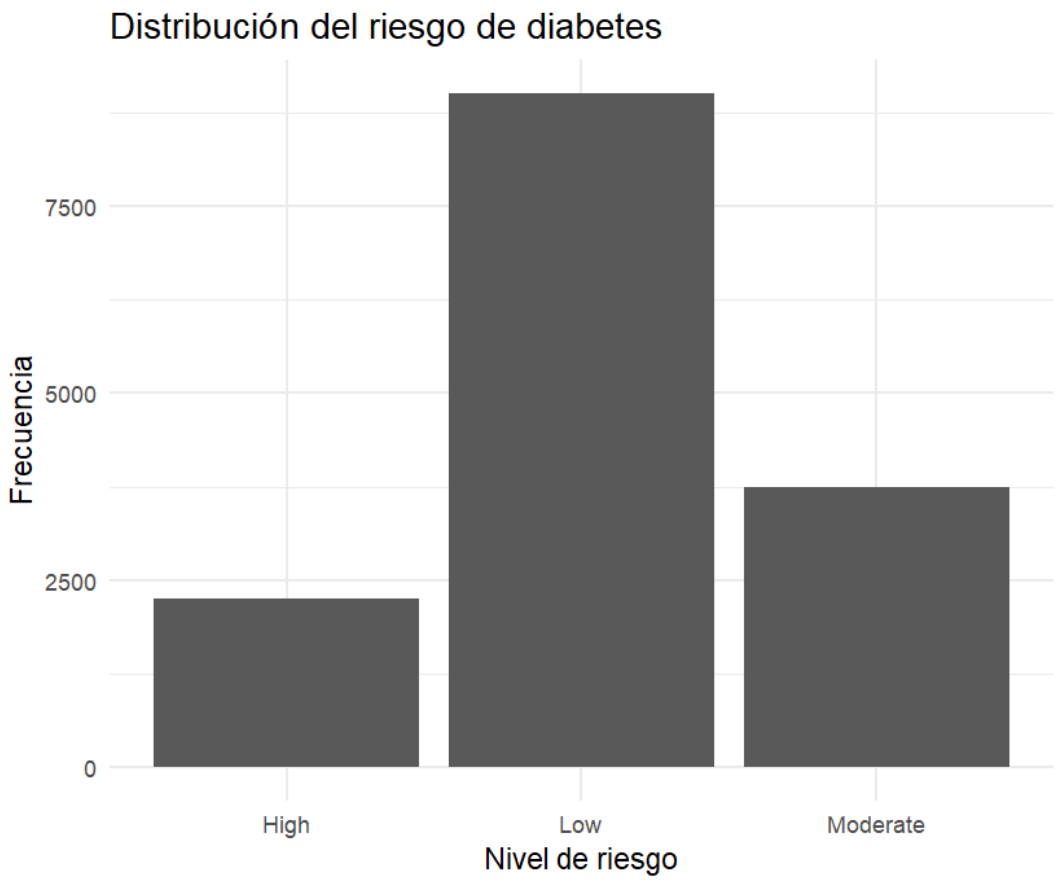


Figura 1. Distribución de diabetes_risk.

La partición se realizó con createDataPartition, p = 0.70 y set.seed(123), conservando aproximadamente la proporción de clases: 10,500 registros para entrenamiento y 4,500 para prueba.

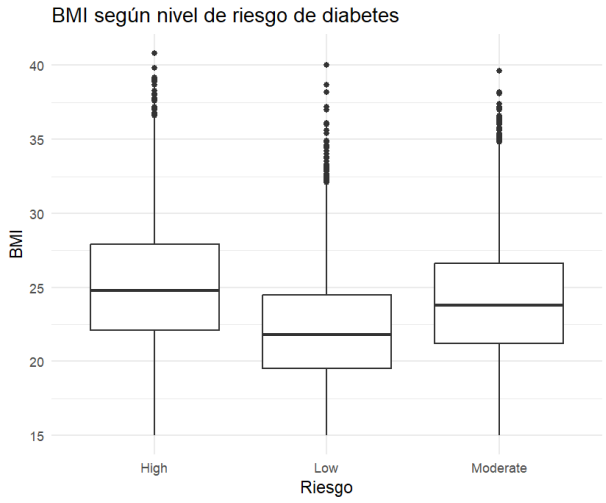
2. EXPLORE (EXPLORACIÓN)

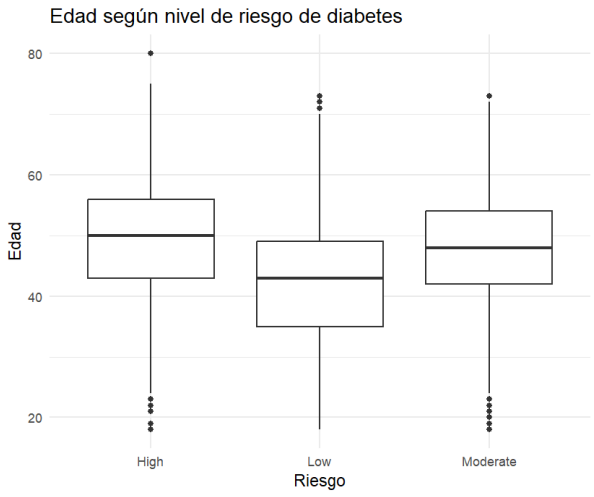
La exploración identificó valores faltantes en tres variables categóricas: smoking_status (472; 3.15%), alcohol_consumption (3,788; 25.25%) e income_bracket (463; 3.09%). El porcentaje de faltantes en alcohol_consumption es especialmente relevante y debe considerarse al interpretar cualquier efecto de esa variable.

Variable	NA	Porcentaje
smoking_status	472	3.15%
alcohol_consumption	3,788	25.25%
income_bracket	463	3.09%

Variable	Low	Moderate	High
age (media)	41.87	47.34	49.17
bmi (media)	22.13	24.06	25.11
fasting_blood_sugar (media)	148.30	183.32	226.54
hba1c_level (media)	6.43	7.20	8.14
waist_circumference_cm (media)	97.92	102.68	105.25

Los promedios aumentan de Low a High en estas variables. La separación es especialmente marcada en fasting_blood_sugar y hba1c_level, patrón que posteriormente también aparece en la estructura e importancia del árbol.





Los boxplots de BMI y edad muestran solapamiento entre categorías. Esto indica que, por sí solas, estas variables no producen una separación completa entre los tres niveles.

3. MODIFY (MODIFICACIÓN)

El preprocesamiento siguió cuatro acciones principales. Primero, se revisaron y eliminaron duplicados, sin embargo, no se encontraron registros repetidos. Segundo, la variable patient_id fue retirada porque funciona como identificador y no como característica predictiva. Tercero, los NA de smoking_status, alcohol_consumption e income_bracket fueron sustituidos por la categoría Unknown. Finalmente, las variables categóricas y diabetes_risk fueron convertidas a factor.

La decisión de conservar los faltantes categóricos como Unknown evito que eliminaramos observaciones así como permitió que el modelo trate la ausencia de información como una categoría.

4. MODEL — CONSTRUCCIÓN DEL MODELO

Se ajustó un árbol de decisión multiclase mediante rpart con method = "class". Los parámetros iniciales fueron cp = 0.001, minsplit = 20, maxdepth = 4 y xval = 10. La validación cruzada interna se utilizó para estudiar el error relativo según la complejidad.

Las variables efectivamente utilizadas para construir divisiones fueron age, fasting_blood_sugar, hba1c_level y waist_circumference_cm. La primera división del árbol se basa en fasting_blood_sugar, lo que evidencia su papel dominante en la estructura de decisión.

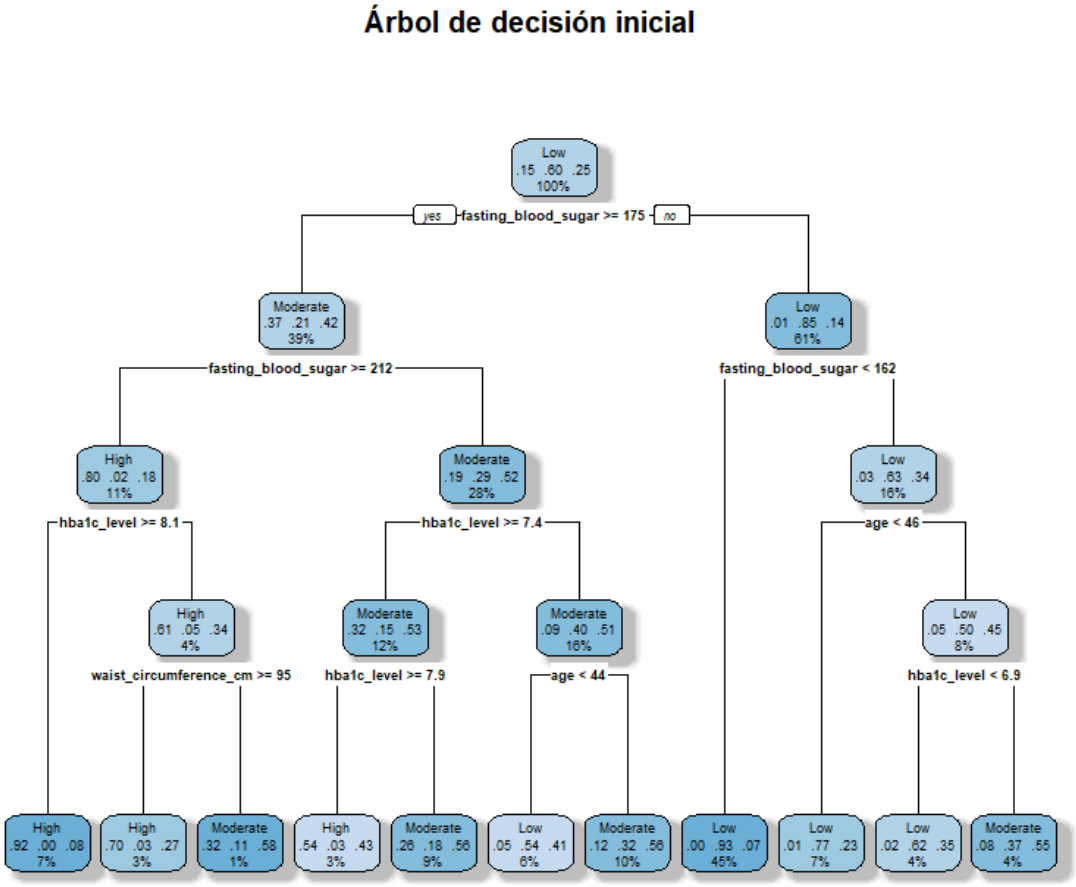


Figura 4. Árbol de decisión inicial.

La tabla de complejidad muestra una reducción importante del error de validación cruzada al aumentar el tamaño del árbol. El mínimo xerror observado fue 0.59810 en CP = 0.001, por lo que ese valor fue seleccionado como CP óptimo.

CP	nsplit	rel error	xerror	xstd
0.2042857	0	1.00000	1.00000	0.011952
0.1764286	1	0.79571	0.79786	0.011373
0.0090476	2	0.61929	0.62571	0.010568
0.0071429	4	0.60119	0.61452	0.010505
0.0061905	5	0.59405	0.62143	0.010544
0.0034524	8	0.57548	0.61119	0.010485
0.0010000	10	0.56857	0.59810	0.010408

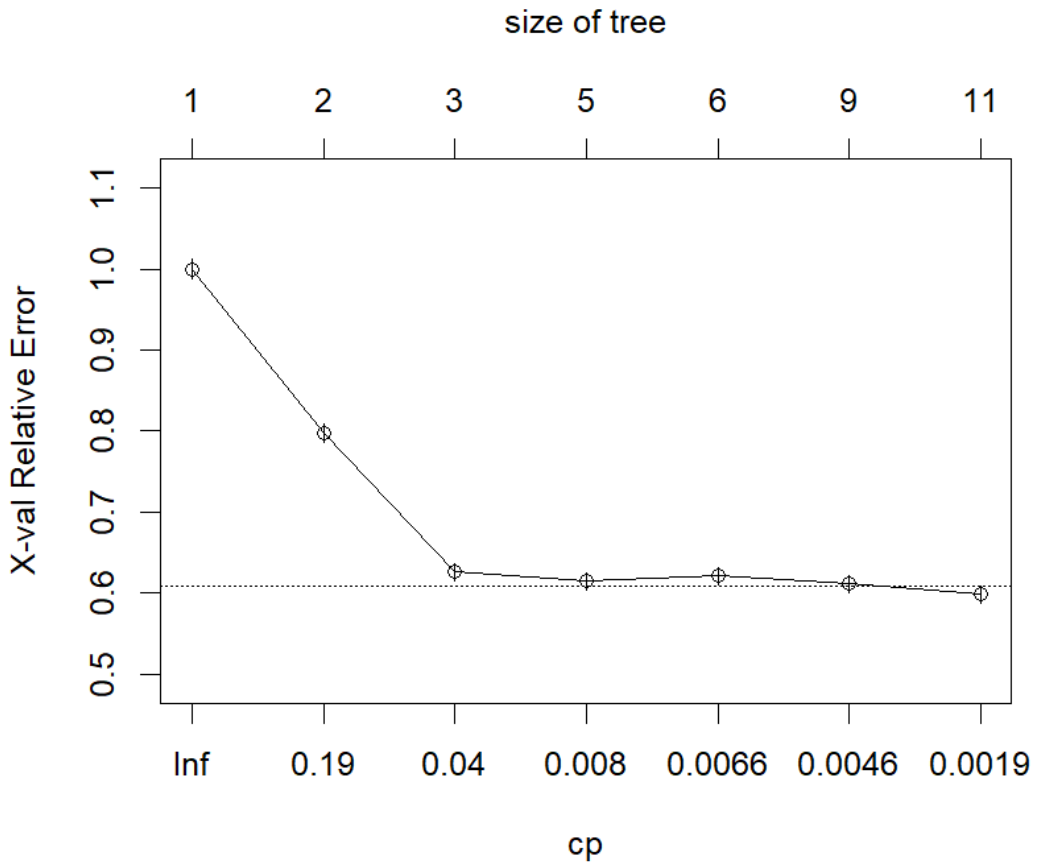


Figura 5. Error relativo de validación cruzada frente al parámetro de complejidad.

Con CP = 0.001, la poda no redujo el árbol respecto del ajuste mostrado y el modelo final conservó 11 hojas terminales. Esto es coherente con que el menor xerror se localizó en el nivel de complejidad más alto evaluado.

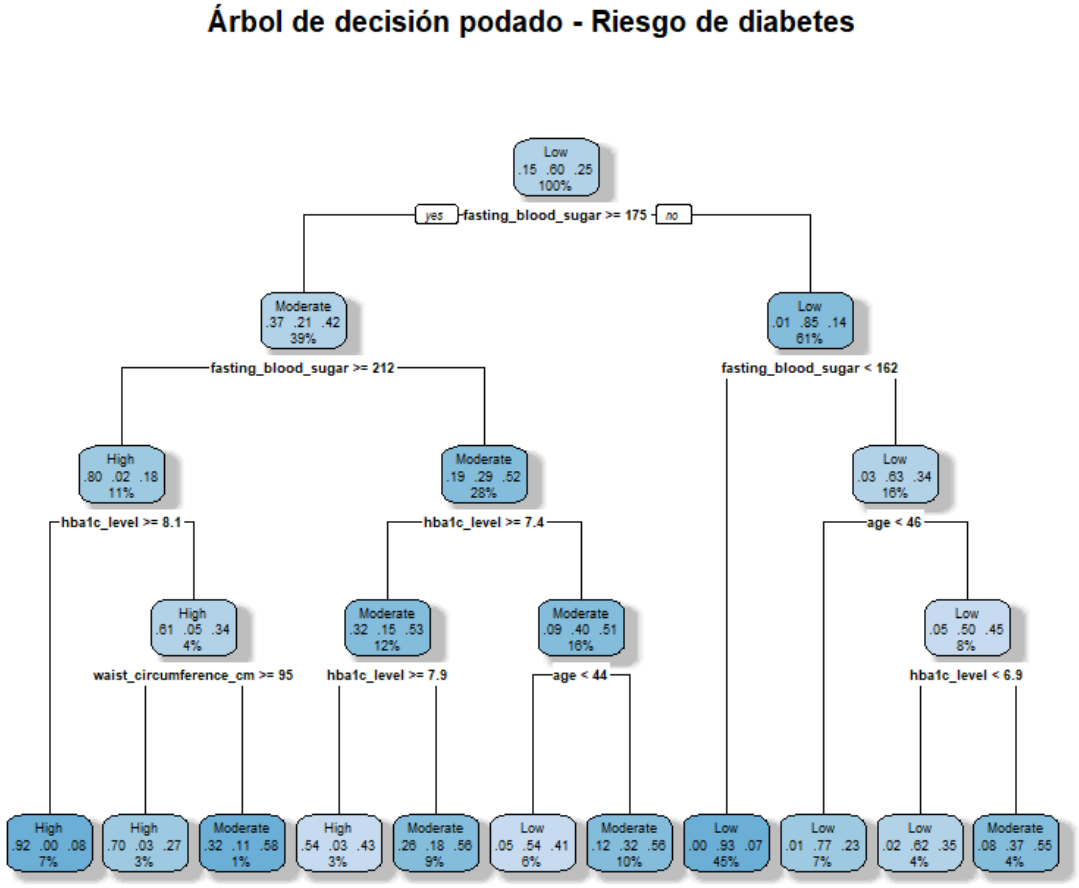


Figura 6. Árbol de decisión final (podado).

7. ASSESS — EVALUACIÓN DEL MODELO

La evaluación se realizó exclusivamente sobre las 4,500 observaciones reservadas para prueba. La matriz de confusión contiene 3,499 clasificaciones correctas, equivalentes a un accuracy de 77.76%. El intervalo de confianza de 95% reportado por caret fue 76.51%–78.96%.

Predicción \ Real	High	Low	Moderate	Total pred.
High	483	12	129	624
Low	8	2,380	360	2,748
Moderate	184	308	636	1,128
Total real	675	2,700	1,125	4,500

El No Information Rate fue 60%, correspondiente a predecir siempre la clase mayoritaria Low. La prueba de accuracy frente a esa tasa produjo p < 2.2e-16, por

lo que el desempeño observado supera estadísticamente ese referente simple. Este contraste no constituye, por sí mismo, evidencia de utilidad clínica.

El coeficiente Kappa fue 0.5957. Esta métrica incorpora el acuerdo esperado por azar y complementa al accuracy en presencia de clases con diferentes prevalencias.

Clase	Sensibilidad	Especificidad	Precisión	F1	Balanced Accuracy
High	71.56%	96.31%	77.40%	74.36%	83.93%
Low	88.15%	79.56%	86.61%	87.37%	83.85%
Moderate	56.53%	85.42%	56.38%	56.46%	70.98%

La clase Low presenta la mayor sensibilidad (88.15%) y el F1 más alto (87.37%). High alcanza sensibilidad de 71.56% y especificidad de 96.31%. Moderate es la clase más difícil: su sensibilidad es 56.53%, su precisión 56.38% y su F1 56.46%. De los 1,125 casos Moderate reales, 636 fueron correctamente identificados, mientras 360 se clasificaron como Low y 129 como High.

En High, 483 de 675 casos reales fueron correctamente detectados; 184 se clasificaron como Moderate y 8 como Low. En Low, 2,380 de 2,700 fueron correctamente clasificados. Estos patrones muestran que buena parte del error ocurre entre categorías adyacentes, especialmente alrededor de Moderate.

Importancia de las variables

Variable	Importancia	Porcentaje
fasting_blood_sugar	2256.864	54.62%
hba1c_level	1467.016	35.51%
age	128.483	3.11%
waist_circumference_cm	107.484	2.60%
bmi	97.667	2.36%
blood_pressure_systolic	53.728	1.30%
blood_pressure_diastolic	9.061	0.22%
physical_activity_level	5.233	0.13%
city	2.725	0.07%
smoking_status	1.731	0.04%
alcohol_consumption	1.623	0.04%
gender	0.187	0.00%

fasting_blood_sugar y hba1c_level concentran 90.13% de la importancia total calculada. En un segundo nivel aparecen age, waist_circumference_cm y BMI. Algunas variables pueden recibir importancia, aunque no aparezcan como divisiones principales del árbol, debido al cálculo interno de importancia de rpart, que puede considerar divisiones sustitutas. Por ello, la tabla debe leerse como contribución predictiva relativa dentro del modelo.

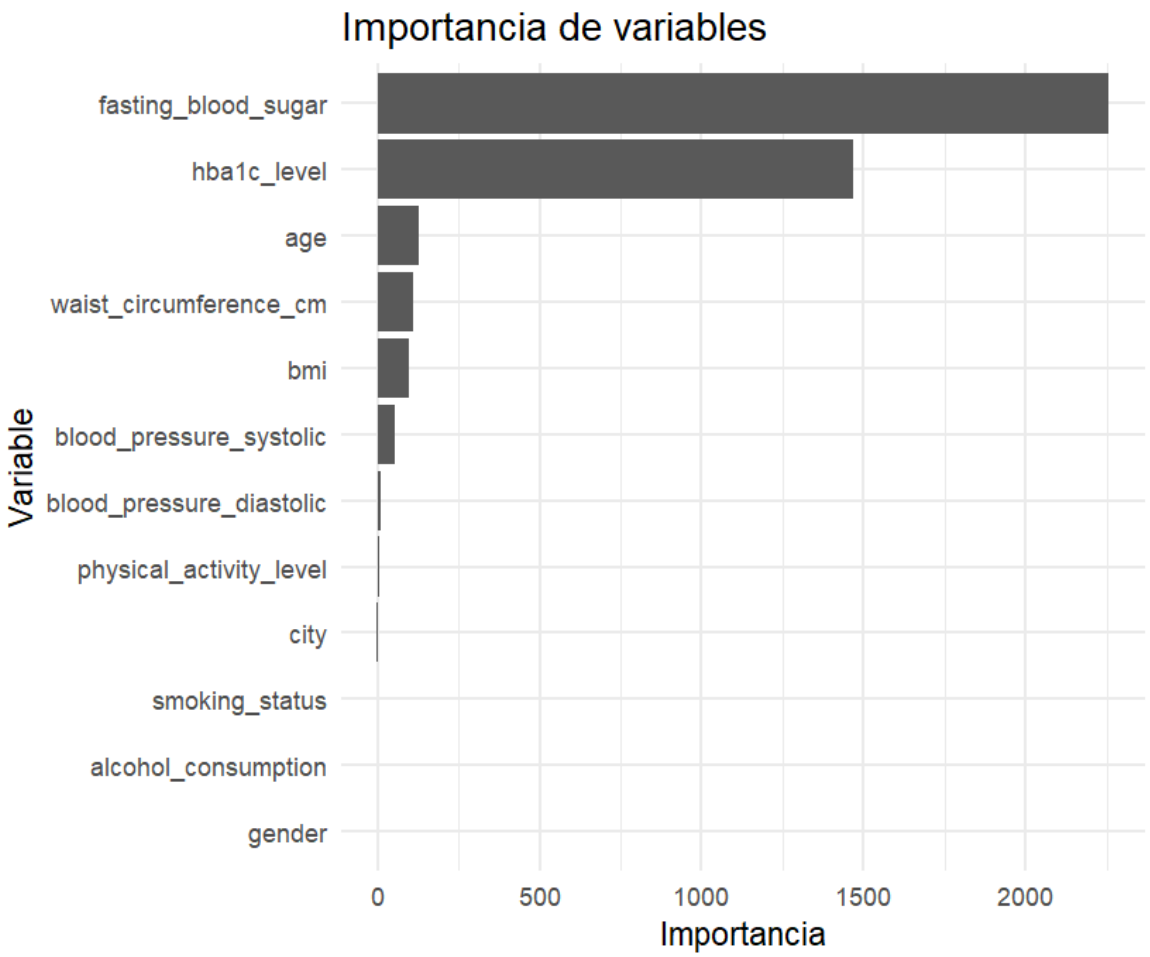


Figura 7. Importancia de variables en el árbol final.

CONCLUSIONES

La aplicación de SEMMA permitió organizar el proyecto desde la caracterización y preparación de los datos hasta la evaluación objetiva del modelo. El árbol final alcanzó 77.76% de accuracy y Kappa de 0.5957 sobre 4,500 observaciones de prueba.

El desempeño fue más sólido para Low y High que para Moderate. La clase Moderate registró la menor sensibilidad (56.53%) y exactitud balanceada (70.98%), por lo que cualquier mejora posterior debería prestar especial atención a la separación de esta categoría.

fasting_blood_sugar y hba1c_level dominaron la predicción, acumulando 90.13% de la importancia del modelo. El árbol también incorporó edad y circunferencia de cintura en sus reglas de decisión. En conjunto, el modelo ofrece una representación interpretable de los patrones de la base, pero requiere validación adicional antes de cualquier uso fuera del contexto analítico de este proyecto.

REFERENCIAS

- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). Classification and Regression Trees. Wadsworth.
- Therneau, T., Atkinson, B., & Ripley, B. rpart: Recursive Partitioning and Regression Trees. Paquete de R utilizado para el ajuste del árbol.
- Kuhn, M. caret: Classification and Regression Training. Paquete de R utilizado para partición y matriz de confusión.
- SAS Institute. SEMMA: Sample, Explore, Modify, Model, Assess. Marco metodológico asociado históricamente con SAS Enterprise Miner.
- Aggarwal, (s. f.). Diabetes risk prediction https://www.kaggle.com/datasets/mansiaggarwal88/diabetes-risk-prediction